

计算机辅助设计与图形学学报

Journal of Computer-Aided Design & Computer Graphics

ISSN 1003-9775, CN 11-2925/TP

《计算机辅助设计与图形学学报》网络首发论文

题目: 基于深度神经网络的遥感图像彩色化方法
作者: 冯佳男, 江倩, 金鑫, 李昕洁, 黄珊珊, 姚绍文
收稿日期: 2020-10-29
网络首发日期: 2021-09-10
引用格式: 冯佳男, 江倩, 金鑫, 李昕洁, 黄珊珊, 姚绍文. 基于深度神经网络的遥感图像彩色化方法. 计算机辅助设计与图形学学报.
<https://kns.cnki.net/kcms/detail/11.2925.TP.20210910.1506.008.html>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

基于深度神经网络的遥感图像彩色化方法

冯佳男^{1,2)}, 江倩^{1,2)*}, 金鑫^{1,2)}, 李昕洁³⁾, 黄珊珊^{1,2)}, 姚绍文^{1,2)}

¹⁾ (云南大学软件学院 昆明 650504)

²⁾ (云南大学跨境网络空间安全教育部工程研究中心 昆明 650504)

³⁾ (新竹交通大学科技管理研究所 新竹 30010)

(jiangqian_1221@163.com)

摘 要: 为了实现遥感图像彩色化, 解决目前彩色化模型存在颜色不准确和颜色溢出等问题, 提出一种端到端的深度神经网络模型. 首先, 通过构建多尺度残差感受域块提取丰富的高维特征; 其次, 利用 U-Net、复杂残差结构、注意力机制和子像素向上卷积等结构构建一个彩色信息重建网络输出彩色化结果; 最后, 使用 NWPU-RESISC45 遥感图像数据集进行训练和验证. 结果表明, 与其他自动彩色化方法相比, 所提方法的 PSNR 值平均提高 6~10 dB, SSIM 值增加 0.05~0.11, 实现了遥感图像彩色化. 此外, 该方法在 RSSCN7 和 AID 数据集上也取得了良好的彩色化效果.

关键词: 深度神经网络; 遥感图像; 图像彩色化

中图法分类号: TP391.41 DOI: 10.3724/SP.J.1089.2021.18747

Remote Sensing Image Colorization Based on Deep Neural Networks with Multi-Scale Residual Receptive Filed

Feng Jia'nan^{1,2)}, Jiang Qian^{1,2)*}, Jin Xin^{1,2)}, Lee Shin-Jye³⁾, Huang Shanshan^{1,2)}, and Yao Shaowen^{1,2)}

¹⁾ (School of Software, Yunnan University, Kunming 650504)

²⁾ (Engineering Research Center of Cyberspace, Yunnan University, Kunming 650504)

³⁾ (Institute of Technology Management, Xinzhu Chiao Tung University, Xinzhu 30010)

Abstract: To solve the problems of mistaken coloring and color bleeding in the current colorization methods, an end-to-end deep neural network is proposed to achieve remote sensing image colorization. First, the multi-scale residual receptive filed net is introduced to extract the key features of source image. Second, a color information recovery network is constructed by using U-Net, complex residual structure, attention mechanism, squeeze and excitation and pixel-shuffle blocks to obtain color result. NWPU-RESISC45 dataset is chosen for model training and validation. Compared with other color methods, the PSNR value of the proposed method is increased by 6-10 dB on average and the SSIM value is increased by 0.05-0.11. In addition, the proposed method also achieves satisfactory color results on RSSCN7 and AID datasets.

Key words: deep neural network; remote sensing; image colorization

收稿日期: 2020-10-29; 修回日期: 2021-06-29. 基金项目: 国家自然科学基金(61863036, 62002313); 中国博士后科学基金(2019M653507, 2020T130564); 云南省重点领域科技计划(202001BB050076); 云南大学第 12 届研究生科研创新项目(2020231). 冯佳男(1997—), 男, 硕士研究生, 主要研究方向为深度学习、计算机视觉; 江倩(1987—), 女, 博士, 助理研究员, 论文通讯作者, 主要研究方向为机器学习、图像处理、生物信息; 金鑫(1987—), 男, 博士, 副教授, 硕士生导师, CCF 会员, 主要研究方向为人工智能神经网络理论与应用、图像处理、遥感信息处理; 李昕洁(1974—), 男, 博士, 教授, 硕士生导师, 主要研究方向为机器学习、决策支持系统; 黄珊珊(1995—), 女, 硕士研究生, 主要研究方向为计算机视觉、图像处理、图像融合; 姚绍文(1966—), 男, 博士, 教授, 博士生导师, 主要研究方向为神经网络理论与应用、云计算、大数据.

遥感图像是记录了丛林、地面田径、矩形农田、房屋建筑和山地等各种地物的电磁波反射照片,凭借信息量大、宏观和动态监测等特点,可有效地帮助人们观察了解地球信息.近年来,遥感图像与场景分类、目标检测和目标定位等多种技术结合,为人们提供了许多有价值的实际应用^[1-2].图像彩色化方法可将给定的灰度级图像转换为彩色图像,增加遥感图像的色彩信息,提高视觉效果,一直是计算机视觉领域的探索热点^[3-8]之一.近年来,图像彩色化技术在历史照片还原、影视制作和壁画修复等方面得到广泛应用,受到国内外众多学者的关注.因此,本文将彩色化技术应用于遥感图像,可通过丰富遥感图像视觉信息进一步发挥其价值.

深度神经网络(deep neural networks, DNN)在近年来在计算机视觉领域表现优异,超越了许多传统方法.卷积神经网络(convolutional neural networks, CNN)、生成对抗网络(generative adversarial networks, GAN)等模型在图像生成任务中发挥了重要的作用.基于 DNN 的彩色化方法可分为非自动彩色化方法和自动彩色化方法,其中非自动彩色化方法在彩色化过程中需要人工介入,而自动化彩色化方法能够独立地完成彩色化任务.

非自动彩色化方法通过人工干预的方式补足色彩信息,实现图像彩色化,它可大体分为基于涂鸦的彩色化方法和基于参考图的彩色化方法 2 大类.基于涂鸦的彩色化方法从人工提供色彩标记或涂鸦入手,如在灰度图像上添加一些彩色点或线条,通过扩散或变分等方法将这些涂鸦扩散到整幅图像,完成图像彩色化.上述方法需要人为提供初始彩色涂鸦,为彩色化过程带来不便.基于参考图的彩色化方法是将场景类似和颜色分布相近的参考图像的色彩信息转移至目标图像上,但其需要人为设定参考图像,单幅与场景类似和颜色相近的参考图像不易寻找.以上 2 种方法不仅需要大量的人工介入,还易受人工涂鸦色彩和参考图像色彩的影响,错误的色彩参考或涂鸦信息有可能造成不合常理的彩色化效果.

自动彩色化方法能够直接将输入的灰度图像转换成彩色图像,大大减轻了用户的负担.Zhang 等^[4]将图像彩色化视为分类问题,将图像亮度信息输入 CNN 模型得到特征信息,再根据颜色分布概率获得色度信息.该方法的网络结构较为简单,彩色化后的图像饱和度较低.Iizuka 等^[5]引入全局特征提取网络,结合先验信息完成上色,但其在颜色变

化不明显的图像上会失效.Yoo 等^[6]提出了新颖的增强型记忆网络,并使用条件 GAN 实现了小样本的彩色化.但是 GAN 在学习的过程中很容易发生模型崩溃的情况,如生成器只会产生一种结果,导致判别器无法有效地监督生成器继续学习,进而无法继续训练.Su 等^[7]利用预训练的 Mask R-CNN 分割出目标图像和背景图像,再将两者分别上色,最后融合成一幅完整的彩色图像.该方法非常依赖于分割处理算法,对于分割处理失败的图像,上色效果一般,而且将目标图像和背景图像分开上色也会导致整体颜色过渡不协调.Isola 等^[8]在目标函数和网络结构上对条件 GAN 进行了改进,最终成功地完成了各类的图像转换任务.Isola 等^[8]在损失函数中引入约束项,用 U-Net 结构替代传统的编解码结构,并提出了 PatchGAN 的判别器结构.然而,基于条件 GAN 的方法仍存在难训练,生成分布单一等问题.

针对上述方法出现的颜色溢出、上色不准确和模型不稳定等问题,本文提出了一种端到端的深度神经网络彩色化模型.首先,构建了多尺度残差感受域块(multi-scale residual receptive field block, MRRFB),利用多个 MRRFB 构成的多尺度残差感受域网络(multi-scale residual receptive field network, MRRF-Net)提取输入图像的特征信息;并以 U-Net 为基本结构,构建色彩信息重建网络(color information recovery networks, CIR-Net)恢复色彩信息.

本文贡献如下:(1) 根据在图像分类任务表现优异的 Inception 模型结构,提出了 MRRFB,并搭建了以此为基础的 MRRF-Net,对输入图像进行充分的抽象特征提取;(2) 搭建了以 U-Net 为主体结构的 CIR-Net;(3) 在 CIR-Net 中使用注意力机制结构代替原本的跳层结构,赋予各个通道不同的权重系数,传递更有价值的特征信息;(4) 在整个网络的上采样过程中,用子像素向上卷积操作替代反卷积操作,在一定程度上减少计算量.

1 相关理论

1.1 CNN

近年来,大规模数据收集和计算机硬件的发展帮助 CNN 在图像分类、图像检测和图像生成等计算机视觉任务中取得了优异的成效.早期的 CNN 模型能够解决手写数字识别等简单分类问题;而更为复杂的 CNN 模型能够完成 ImageNet 数

据集上千类别的分类任务^[9]. CNN 逐渐成为一种流行的机器学习模型, 并得到广泛应用.

在图像分类任务中, 通常 CNN 模型包含多个卷积层和池化层, 卷积层和池化层不断交替, 后面再连接一些全连接层, 最后为输出层. 为了适应其他的计算机视觉任务, 全卷积网络将全连接层转化为卷积层, 得到了与原输入大小一致甚至更大的输出.

CNN 中前面的卷积层只需要感受图像局部区域的特征, 如线条和边缘, 而更高的卷积层用于提取更高维度的全局特征. 同一个特征通道上的卷积核参数是相同的, 这样可以大大地减少神经网络需要训练的参数个数. 与一般的神经网络相比, 局部特征的感受和权重共享能够帮助 CNN 更好地适应图像结构, 提取其中的特征信息, 使其有效地应用于计算机视觉的多种任务.

1.2 彩色空间理论

色彩空间将人们对颜色的主观感受量化为具体的数值表达, 为计算机记录和分析色彩提供了理论的依据. 色彩空间的表达是多样性的, 不同的色彩空间具备不同的特点, 常用的色彩空间有 RGB, Lab, HSV 和 YUV 等. 根据色彩混合的基本

定律, RGB 色彩空间可以表达自然界任何色彩, 其中, R , G , B 分别代表红、绿、蓝 3 种原色光, 其数值范围为 0~255. Lab 色彩空间由亮度通道 L 和颜色通道 a 和 b 组成, L 通道的数值范围为 0(黑色)~100(白色), a 通道的数值范围为 -128(绿色)~127(红色), b 通道的数值范围为 -128(蓝色)~127(黄色).

在彩色化任务中多采用 Lab 模型, 根据亮度通道 L 预测颜色通道 a 和 b , 结合输入的 L 通道形成完整的 Lab 图像; 其中, L 通道是固定的. 而本文提出的彩色化方法采用了 RGB 颜色空间, 根据灰度图像预测 RGB 彩色图像, 构建了端到端的自动彩色化模型, 避免了色彩空间变换. 本文方法与预测 a 和 b 通道的彩色化方法相比, 需要预测 3 个通道的颜色信息, 挑战性更大.

1.3 注意力机制

Hu 等^[10]提出了基于注意力机制的挤压激励块 (squeeze-and-excitation block, SE Block), 随后将 SE Block 与 ResNet 结合, 在 ILSVRC2017 的分类竞赛中获得最好成绩. SE Block 侧重于传递价值高的特征, 较少关注次要的特征, 它通过分配特征层的不同权重区分特征信息的重要程度.

SE Block 不改变输入信息的形状, 在略微增加计算成本的情况下, 传递更重要的信息, 可加快网络的训练速度, 图像分类准确率提升显著.

2 本文彩色化方法

如图 1 所示, 本文构建的遥感图像彩色化模型包含 MRRF-Net 和 CIR-Net.




图1 本文模型整体结构图




图2 多尺度残差感受域块

通常,在CNN中大卷积核具有更大的感受域,所获得的全局特征更好.但大卷积核会导致计算量暴增,也不利于加深模型.于是Inception用2个 3×3 的卷积替换一个 5×5 的卷积,用3个 3×3 的卷积替换一个 7×7 的卷积.

MRRFB借鉴了Inception结构,同时引入了残差结构,增强了各个模块之间的关联性,避免网络模型过深而导致梯度消失. MRRFB包含若干条分支,每条分支包含数量和尺寸不同的卷积块,提取不同尺度下的特征信息.

首先, MRRFB利用一个 1×1 的卷积固定特征的通道数,并将特征送入不同分支提取不同尺度的特征信息;再将各个特征信息合并;最后,用一

该结构输入是代表亮度信息的灰度图像,经过MRRF-Net得到抽象的高维特征信息,再经过CIR-Net产生完整的彩色图像.整个网络结构采用 L_1 作为损失函数,与 L_2 损失相比, L_1 损失收敛速度快,且不易发生梯度爆炸的情况.损失函数可表示为

$$L_1 = -\sum_{i=1}^C \sum_{j=1}^H \sum_{k=1}^W (|I_{i,j,k}^{\text{label}} - I_{i,j,k}^{\text{color}}|) \quad (1)$$

其中, C , H , W 分别为图像的通道数、高度和宽度; $I_{i,j,k}^{\text{label}}$ 和 $I_{i,j,k}^{\text{color}}$ 为 (i,j,k) 位置的标签图像和彩色化图像的像素值.

2.1 MRRFB

Szegedy等^[11]提出Inception结构在图像分类任务中取得了优异的成绩,它使用多个小尺寸的卷积核代替大尺寸的卷积核.本文借鉴Inception结构提出了MRRFB,引入了残差结构,与原来的Inception模块相比,具有更深的结构和更大的感受域,如图2所示.

个 1×1 的卷积恢复通道数,得到抽象特征

2.2 CIR-Net

MRRF-Net从输入的灰度图像中提取出丰富的抽象特征,并送入CIR-Net重建色彩信息. U-Net是一种结构对称的模型,最早应用于语义分割任务,近年来得到了广泛的应用. Isola等^[8]使用U-Net作为生成器,因此,本文选择也U-Net作为CIR-Net的主题结构.

CIR-Net具有以下几个特点.

(1) 在上采样过程中,使用子像素向上卷积操作替代反卷积操作完成上采样.子像素向上卷积操作是通过缩小特征的通道数增大特征的分辨率,只是一个改变特征形状的过程,不涉及任何梯度

计算. 因此, 这样做不仅可以保留所有的特征信息, 还可以节省梯度运算.

(2) 在跳层中引入了 SE Block, 对传递过去的特征分配不同的权重, 削弱不重要特征信息对最终结果的负面影响.

(3) 下采样的过程中引入了复杂残差结构, 进一步加深网络, 增强模型的彩色信息重建能力.

如图 3 所示, CIR-Net 左半部分是一个减小特征宽高、增大维度的过程, 而网络右半部分刚好相反. 在网络左半部分的下采样过程中, 特征的维度不断增加, 但特征信息不断减少. 跳层的加入直接将网络左半部分的特征信息直接传递到网络右半部分, 解决了特征信息丢失严重的问题.

2.2.1 复杂残差块

复杂残差块如图 3 中的红色虚线框所示. 与普通 U-Net 中下采样操作不同, 它没有利用跨步卷积或一个卷积和池化操作进行下采样, 而是先进行

彩色特征信息重建, 再进行下采样操作.

在 CIR-Net 的下采样过程中, 特征的通道数增加, 但特征的大小缩减至原来的一半, 通过一个卷积块提取的高维抽象特征有限; 而复杂残差块加深模型的深度, 能够进一步提取高维抽象特征, 同时, 其引入残差结构防止模型过深导致梯度消失.

2.2.2 子像素向上卷积

子像素向上卷积^[12]是图像超分辨率中常用的上采样方法, 它将各个特征图按照一定规则重新组合成一个高分辨率的图像. 在此过程中, 特征的数量不发生任何改变, 通道数锐减, 锐减的程度与放大的倍数有关, 放大倍数越高, 通道数越少. 与反卷积相比, 子像素向上卷积未引入其他参数, 在完成上采样的同时减少梯度更新, 节省训练时间.

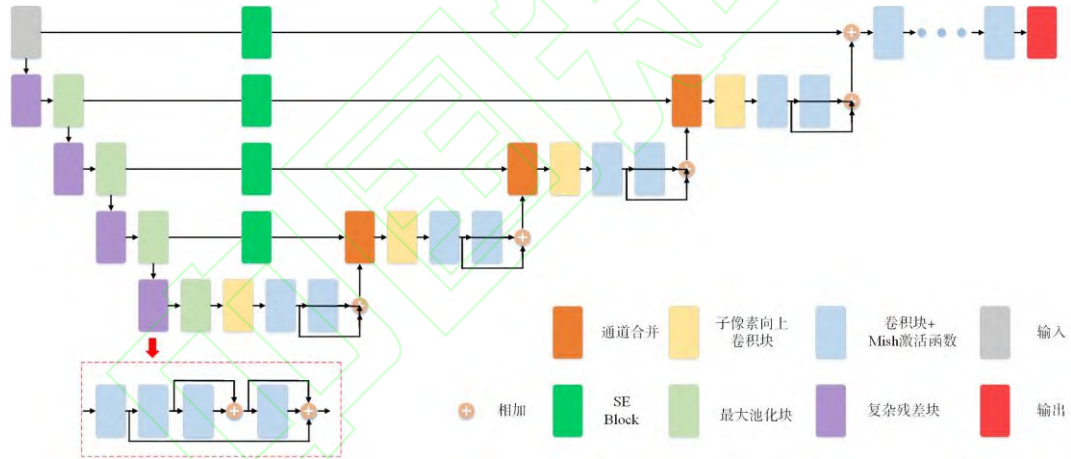


图 3 色彩信息重建网络

由于子像素向上卷积会导致特征通道数量降低, 破坏了 CIR-Net 的对称性, 因此为保证输出足够的特征, 将跳层特征和上采样得到的特征通道合并.

2.2.3 SE Block

SE Block 包含挤压操作和激励操作, 分别为

$$Z_c = F_{sq}(X_c) = \frac{1}{W \times H} \sum_{i=1}^W \sum_{j=1}^H X_c(i, j);$$

$$S = F_{ex}(Z) \otimes Z = \sigma(f_2(f_1(Z))) \otimes Z.$$

其中, F_{sq} 代表挤压操作, 即全局平均池化操作; X_c 代表输入张量的第 c 个通道的二维矩阵; W 和 H 为张量的高和宽; F_{ex} 代表激励操作; Z 代表输入张量; f_2 和 f_1 代表全连接操作; σ 代表 Sigmoid 激活函数; \otimes 代表点积运算.

SE Block 首先利用全局平均池化将每层特征信息全局平均池化得到全局特征值, 随后加入 2 层全连接层, 最后使用 Sigmoid 激活函数输出每层的权重. 与 Softmax 激活函数不同, Sigmoid 激活函数只根据输入的值进行映射, 不会受全连接其他参数值的影响, 降低了复杂度和计算量. SE Block 结构如图 4 所示.

3 实验结果与分析

3.1 实验环境及训练参数

为验证本文提出的深度神经网络模型在实现遥感图像彩色化的有效性, 使用 Python3.7 和 PyTorch1.5 搭建神经网络模型, 在配置为 NVIDIA RTX TITAN 的 Windows 服务器上训练和测试.

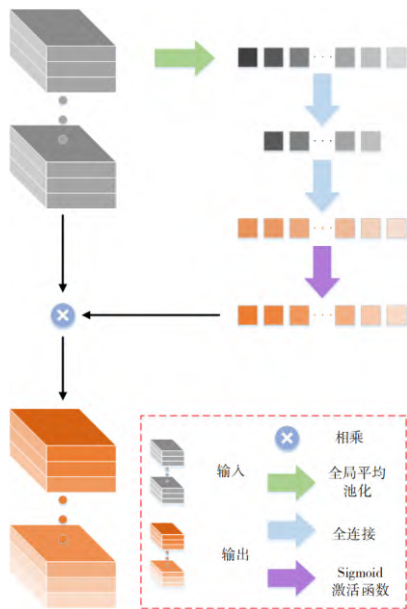


图 4 SE Block

在网络的训练中, 设定批大小为 6, 在训练集中设置了随机旋转和对称翻转, 以增强模型的泛化性能. 本文采用 Adam 作为网络的优化器, 初始学习率设置为 0.000 1, 根据式(1)计算得到的损失值对整体模型进行参数优化, 在每完成 30 个迭代训练后, 调整学习率为原来的 0.8.

3.2 数据集及评价指标

NWPU-RESISC45 数据集涵盖 45 个类别场景的遥感图像, 实验从中选取了 16 个类别共计 9920 幅图像作为训练集, 以及 800 幅图像作为测试集, 利用 OpenCV 包将原始图像转换成灰度图像作为彩色化模型的输入. 为证明本文方法具有较强的泛化性, 在 RSSCN7 数据集和 AID 数据集上进行测试, 数据集选择详细如下.

(1) 实验从 NWPU-RESISC45 数据集(分辨率 256×256 像素)中选取了 16 类遥感图像作为训练集和测试集, 分别为 forest, golf_course, railway, stadium, baseball_diamond, rectangular_farmland,

overpass, circular_farmland, freeway, dense_residential, runway, sparse_residential, medium_residential, tennis_court, mobile_home_park 和 roundabout.

(2) 实验从 RSSCN7 数据集(分辨率 400×400 像素)中选取了 6 类遥感图像作为测试集, 分别为 grass, field, industry, forest, resident 和 parking.

(3) 实验从 AID 数据集(分辨率 600×600 像素)中选取 20 类遥感图像作为测试集, 分别为 airport, baseball_field, center, forest, church, commercial, dense_residential, farmland, industrial, meadow, parking, medium_residential, railway_station, resort, school, stadium, sparse_residential, viaduct, square 和 storage_tanks.

本文使用的客观图像质量评价指标为峰值信噪比(peak signal to noise ratio, PSNR)、结构相似度(structural similarity index, SSIM)、均方误差(mean square error, MSE)、平均绝对误差(mean absolute error, MAE)和皮尔逊相关系数(Pearson correlation coefficient, PCC). PSNR 代表了图像蕴含的信息量的丰富程度, PSNR 为 30~40 dB 说明图像接近原始图像; SSIM 和 PCC 用于评判生成图像与真实标签的相关性, 越接近 1, 说明与真实标签越相似; MSE 和 MAE 是评判生成图像和真实标签之间的距离差值, 差值越小越好.

3.3 消融实验

为了验证各个模块的有效性, 本文进行了关于多尺度残差感受域模块、复杂残差块和 SE Block 的消融实验. 表 1 所示为消融实验得到的结果. 可以看出, 本文方法具有绝对的优势.

表 1 各模块消融实验对比

结构	PSNR/dB	SSIM	MSE	MAE	PCC
本文	39.347 8	0.992 2	7.88	81.9	0.994
使用 Inception ^[11] 替代 MRRFB	36.098 6	0.990 5	16.16	97.7	0.991
去除 SE Block ^[10]	35.563 7	0.990 2	17.63	96.8	0.989
复杂残差块去除一个残差结构	35.707 4	0.990 0	17.15	95.2	0.990

3.4 实验对比与结果分析

为进一步说明本文方法的有效性, 将其与文献[5-8]的彩色化方法进行对比实验, 结果如表 2 所

示. 由表 2 可知, 本文方法在平均 PSNR 上远高于其他彩色化方法, 所生成的彩色图像包含更多的色彩信息和细节信息. 在平均 SSIM 上, 本文结果

与真实的标签图像非常所差无几。因此, 本文方法的彩色化结果具有更高的着色精度和更好的图像质量。

表 2 不同方法对比实验

方法	PSNR/dB	SSIM	MSE	MAE	PCC
文献[8]	33.366	0.984	26.8	104	0.988
文献[7]	32.972	0.988	30.5	66	0.989
文献[6]	31.068	0.979	37.3	106	0.983
文献[5]	28.547	0.978	65.9	39	0.986
本文	39.347	0.992	7.8	81	0.994

文献[5]在上色过程中结合了全局特征, MAE 损失很小, 但颜色溢出现象较为严重, 如图 5f 所示, 斑马线边甚至马路中央变成了绿色。文献[6]使用 cGAN, 通过记忆力网络记录色彩特征信息, 然而对复杂场景的图像出现了上色不准确、过渡不协调的现象。例如, 图 6c 所示局部土地颜色过于

鲜艳, 与周围不协调; 图 7e 所示马路的颜色变成了黄色, 图 8e 所示马路边界颜色溢出严重。文献[7]使用目标检测算法分离出目标图像和背景图像, 分别得到彩色结果再进行融合, 但其过于依赖目标检测算法, 出现整体上色失败的情况, 如图 7d 所示。文献[8]利用条件 GAN 完成图像转换任务, 且生成的图像较为清晰, 但颜色单一, 如图 5c、图 6c 和图 7c 所示。

本文方法比其他方法具有更高的 PSNR 和 SSIM, 生成的图像非常接近标签图像, 且不同目标之间颜色过渡自然, 还能完成稀少颜色的上色, 如图 8g 所示。无论主观视觉还是客观指标, 本文方法都更具优势, 生成更令人信服的彩色图像。图 5~图 11 的图像质量指标对比如表 3 所示。




图 5 不同彩色化方法的对比实验 1




图 6 不同彩色化方法的对比实验 2




图 7 不同彩色化方法的对比实验 3



图 8 不同彩色化方法的对比实验 4



图 9 不同彩色化方法的对比实验 5




图 10 不同彩色化方法的对比实验 6




图 11 不同彩色化方法的对比实验 7

表 3 实验 1~实验 7 的图像质量指标对比

图像	文献[8]		文献[7]		文献[6]		文献[5]		本文	
	PSNR/dB	SSIM	PSNR/dB	SSIM	PSNR/dB	SSIM	PSNR/dB	SSIM	PSNR/dB	SSIM
图 5	31.01	0.983	35.63	0.994	29.25	0.983	27.06	0.981	43.68	0.995
图 6	31.02	0.985	34.00	0.991	29.45	0.972	25.16	0.169	43.17	0.993
图 7	32.04	0.988	30.82	0.990	29.66	0.979	26.29	0.969	43.31	0.994
图 8	27.35	0.980	25.72	0.976	27.35	0.974	23.29	0.965	40.73	0.988
图 9	30.26	0.987	31.62	0.990	28.59	0.984	26.85	0.981	42.12	0.994
图 10	30.72	0.980	32.71	0.990	31.70	0.984	26.50	0.978	43.38	0.992
图 11	34.33	0.985	32.46	0.985	31.49	0.973	31.04	0.980	44.08	0.992

在 NWPU-RESISC45 数据集上训练好的模型, 直接在 RSSCN7 数据集和 AID 数据集上进行测试, 以证明本文方法的泛化性效果, 如图 12~图 15 所示; 其中第 1 行为输入的灰度图像, 第 2 行为真实图像, 第 3 行为模型输出的图像. 本文方法增加了不同类别的场景之间的区分度, 且不存在颜色单

一的问题, 但由于未使用 RSSCN7 数据集和 AID 数据集进行训练, 局部的颜色略微有一点偏差, 但整体上色效果较好. 其中, RSSCN7 数据集和 AID 数据集的图像分辨率大于训练图像的分辨率, 在此情况下, 本文方法仍能够取得不错的彩色化效果, 由此也表明了其具有较好的泛化能力.





图 12 RSCNN7 数据集的测试效果 1



图 13 RSCNN7 数据集的测试效果 2

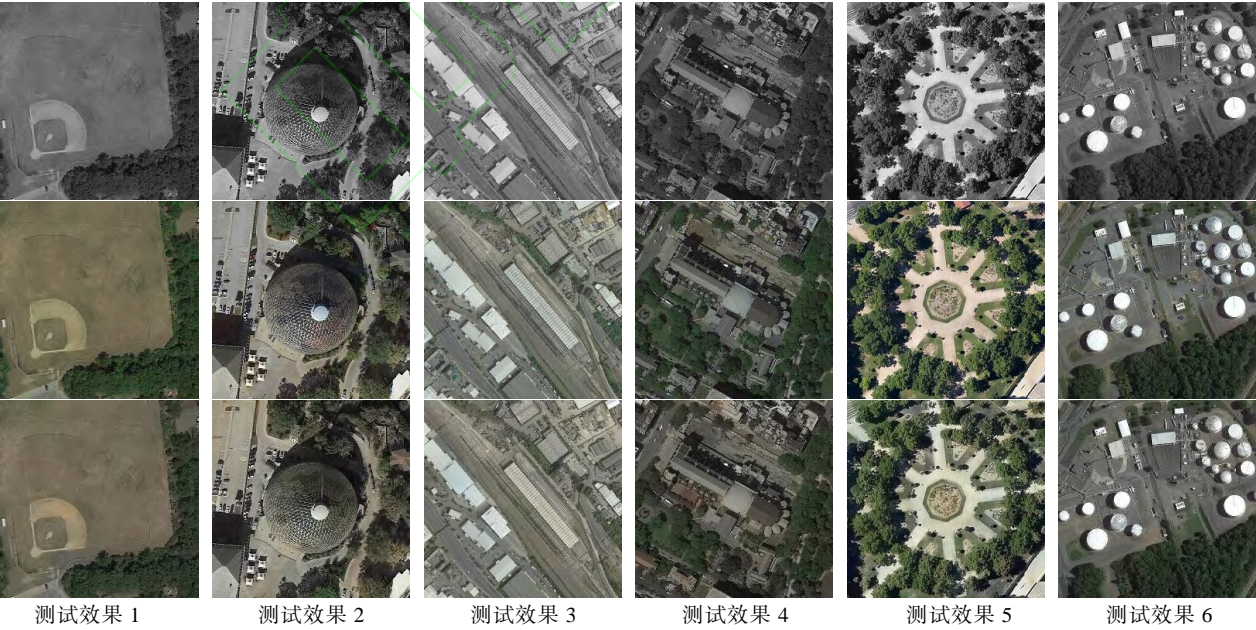


图 14 AID 数据集的测试效果 1

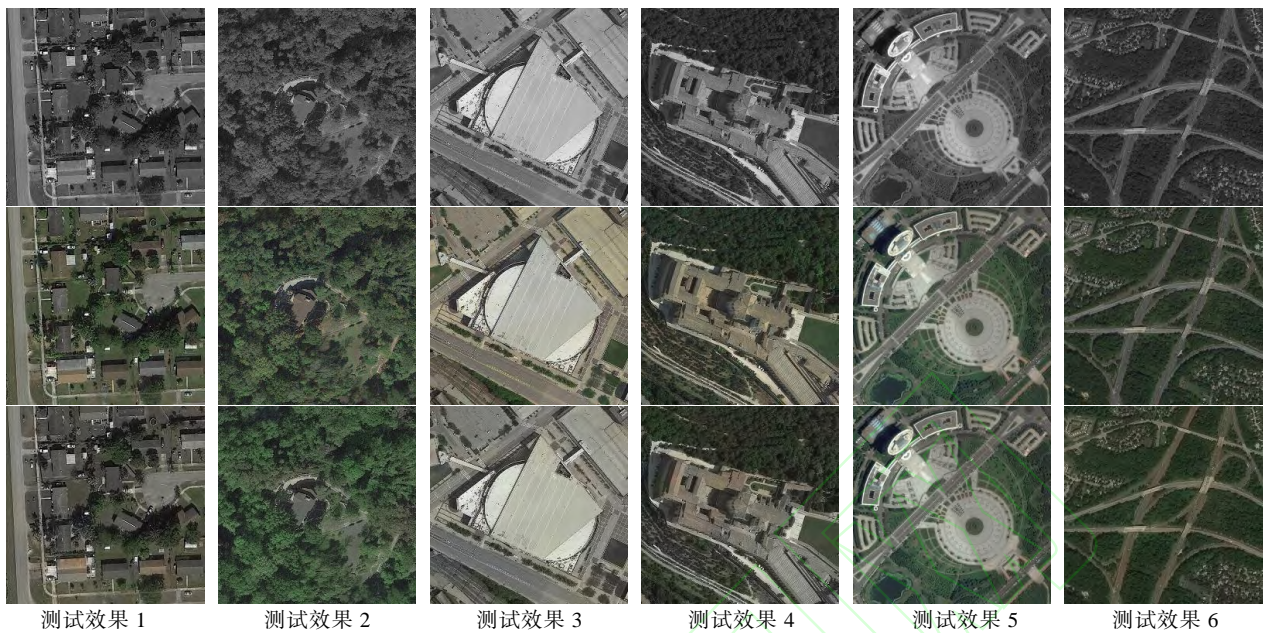


图 15 AID 数据集的测试效果 2

4 结 语

本文提出基于深度学习的遥感图像彩色化方法,使用多尺度残差感受域网络和图像重建网络完成了多个场景的遥感图像的上色.实验表明,与其他的彩色化方法对比,本文方法的彩色化结果具有更加丰富的图像信息,避免了颜色溢出和颜色不准确等问题.下一步工作将拓展本文提出的深度学习模型在其他图像彩色化领域的应用,探索实现复杂场景的图像彩色化任务模型.

参考文献(References):

- [1] Zhong Weifeng, Guo Feng, Xiang Shiming, *et al.* Ship detection in remote sensing based with rotated rectangular region[J]. *Journal of Computer-Aided Design & Computer Graphics*, 2019, 31(11): 1935-1945(in Chinese)
(仲伟峰, 郭峰, 向世明, 等. 旋转矩形区域的遥感图像舰船目标检测模型[J]. *计算机辅助设计与图形学学报*, 2019, 31(11): 1935-1945)
- [2] Zhou Guohua, Jiang Hui, Gu Xiaoping, *et al.* Self-weighted multi-view metric learning and its application for remote sensing image scene classification[J]. *Journal of Computer-Aided Design & Computer Graphics*, 2021, 33(5): 755-764(in Chinese)
(周国华, 蒋晖, 顾晓清, 等. 自适应权重多视角度量学习的遥感图像场景分类方法[J]. *计算机辅助设计与图形学学报*, 2021, 33(5): 755-764)
- [3] Lin Jiajun, Zhuge Jingjing, Zhang Qing. Colorization of complex scene grayscale images with pixel-wise generative adversarial networks[J]. *Journal of Computer-Aided Design & Computer Graphics*, 2019, 31(3): 439-446(in Chinese)
(林家骏, 诸葛晶晶, 张晴. 基于像素级生成对抗网络的复杂场景灰度图像彩色化[J]. *计算机辅助设计与图形学学报*, 2019, 31(3): 439-446)
- [4] Zhang R, Isola P, Efros A A. Colorful image colorization[C] // *Proceedings of the European Conference on Computer Vision*. Heidelberg: Springer, 2016: 649-666
- [5] Iizuka S, Serra-Simó E, Ishikawa H. Let there be color!: Joint end-to-end learning of global and local image priors for automatic image colorization with simultaneous classification[J]. *ACM Transactions on Graphics*, 2016, 32(4): Article No.110
- [6] Yoo S, Bahng H, Chung S, *et al.* Coloring with limited data: Few-Shot colorization via memory augmented networks[C] // *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Los Alamitos: IEEE Computer Society Press, 2019: 11274-11284
- [7] Su J W, Chu H K, Huang J B. Instance-aware image colorization[C] // *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Los Alamitos: IEEE Computer Society Press, 2020: 7965-7974
- [8] Isola P, Zhu J Y, Zhou T H, *et al.* Image-to-image translation with conditional adversarial networks[C] // *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Los Alamitos: IEEE Computer Society Press, 2017: 5967-5976
- [9] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[J]. *Communications of the ACM*, 2017, 60(6): 84-90
- [10] Hu J, Shen L, Albanie S, *et al.* Squeeze-and-excitation networks[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2020, 42(8): 2011-2023
- [11] Szegedy C, Vanhoucke V, Ioffe S, *et al.* Rethinking the inception architecture for computer vision[C] // *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Los Alamitos: IEEE Computer Society Press, 2016: 2818-2826

- [12] Shi W Z, Caballero J, Huszar F, *et al.* Real-time single image and video super-resolution using an efficient sub-pixel convolutional neural network[C] //Proceedings of the IEEE/CVF

Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2016: 1874-1883

